

HỌ VÀ TÊN SINH VIÊN: NGUYỄN ĐÌNH QUÂN

NGÀNH: CÔNG NGHỆ THÔNG TIN VIỆT NHẬT

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC PHENIKAA



ĐỒ ÁN TỐT NGHIỆP:
SỬ DỤNG REINFORCEMENT LEARNING KẾT
HỢP THUẬT TOÁN DOUBLE AUCTION CHO QUẢN
LÝ TÀI NGUYÊN TRONG DỊCH VỤ AI TẠO SINH

Sinh viên: Nguyễn Đình Quân

Mã số sinh viên: 20010979

Khóa: 14

Ngành: Công nghệ thông tin Việt Nhật Hệ: Đại học chính quy

Giảng viên hướng dẫn: Tiến sĩ Nguyễn Công Lượng

Hà Nội – Năm 2025

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC PHENIKAA



ĐỒ ÁN TỐT NGHIỆP:

**SỬ DỤNG REINFORCEMENT LEARNING KẾT
HỢP THUẬT TOÁN DOUBLE AUCTION CHO QUẢN
LÝ TÀI NGUYÊN TRONG DỊCH VỤ AI TẠO SINH**

Sinh viên: Nguyễn Đình Quân

Mã sinh viên: 20010979

Khóa: 14

Ngành: Công nghệ thông tin Việt Nhật

Hệ: Đại học chính quy

Giảng viên hướng dẫn: Tiến sĩ Nguyễn Công Lượng

Hà Nội – Năm 2025

LỜI CAM ĐOAN

Tên tôi là: Nguyễn Đình Quân

Mã sinh viên: 20010979

Lớp: Công nghệ thông tin Việt Nhật

Ngành: Công nghệ thông tin Việt Nhật

Tôi đã thực hiện đồ án/khóa luận tốt nghiệp với đề tài: Sử dụng Reinforcement learning kết hợp thuật toán Double auction cho quản lý tài nguyên trong dịch vụ AI tạo sinh.

Tôi xin cam đoan đây là đề tài nghiên cứu của riêng tôi và được sự hướng dẫn của: Tiến sĩ Nguyễn Công Lượng.

Các nội dung nghiên cứu, kết quả trong đề tài này là trung thực và chưa được các tác giả khác công bố dưới bất kỳ hình thức nào. Nếu phát hiện có bất kỳ hình thức gian lận nào tôi xin hoàn toàn chịu trách nhiệm trước pháp luật.

Hà Nội, ngày 3 tháng 6 năm 2025

GIẢNG VIÊN HƯỚNG DẪN

(Ký, ghi rõ họ tên)

SINH VIÊN

(Ký, ghi rõ họ tên)

BỘ GIÁO DỤC VÀ ĐÀO TẠO
NAM

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT

TRƯỜNG ĐẠI HỌC PHENIKAA
phúc

Độc lập – Tự do – Hạnh

**NHẬN XÉT ĐỒ ÁN/KHÓA LUẬN TỐT NGHIỆP
CỦA GIẢNG VIÊN HƯỚNG DẪN**

Giảng viên hướng dẫn:

Bộ môn:

.....

Tên đề tài:

.....

.....

Sinh viên thực hiện: Lớp:

.....

NỘI DUNG NHẬN XÉT

I. Nhận xét ĐAKLTN:

- Nhận xét về hình thức:

.....

.....

.....

- Tính cấp thiết của đề tài:

.....

.....

.....

.....

- Mục tiêu của đề tài:

.....

.....

.....

.....

- Nội dung của đề tài:

.....

.....

.....

- Tài liệu tham khảo:

.....

.....

.....

.....

- Phương pháp nghiên cứu:

.....

.....

.....

- Tính sáng tạo và ứng dụng:

.....

.....

.....

II. Nhận xét tinh thần và thái độ làm việc của sinh viên:

.....

.....

III. Kết quả đạt được:

.....

.....

.....

.....

.....

IV. Kết luận: Đồng ý cho ☐ về:

Không đồng ý cho ☐

bảo vệ:

Hà Nội, ngày ... tháng ... năm 20...

GIẢNG VIÊN HƯỚNG DẪN

(Ký, ghi rõ họ tên)

vi

BỘ GIÁO DỤC VÀ ĐÀO TẠO
NAM

CỘNG HÒA XÃ HỘI CHỦ NGHĨA VIỆT

TRƯỜNG ĐẠI HỌC PHENIKAA

Độc lập – Tự do – Hạnh

phúc

NHẬN XÉT ĐỒ ÁN/KHÓA LUẬN TỐT NGHIỆP
CỦA GIẢNG VIÊN PHẢN BIỆN

Giảng viên phản biện: Bộ
môn:

.....

Tên đề tài:

.....

.....

Sinh viên thực hiện: Lớp:

.....

Giảng viên hướng dẫn:

.....

NỘI DUNG NHẬN XÉT

I. Nhận xét ĐAKLTN:

- Bố cục, hình thức trình bày:

.....

.....

- Đảm bảo tính cấp thiết, hiện đại, không trùng lặp:

.....

.....

- Nội dung:

.....

.....

- Mức độ thực hiện:

.....

.....

II. Kết quả đạt được:

.....

.....

III. Ưu nhược điểm:

.....

.....

IV. Kết luận: Đồng ý cho ☐ về: Không đồng ý cho ☐
bảo vệ:

Hà Nội, ngày.....tháng.....năm 20.....

GIẢNG VIÊN PHẢN BIỆN

(Ký, ghi rõ họ tên)

(Tóm tắt đồ án/khóa luận tốt nghiệp)

Đồ án tốt nghiệp của tôi sử dụng Multi Agent Deep Reinforcement learning, cụ thể là thuật toán Multi Agent Proximal Policy Optimization để huấn luyện các GAISP hành động đặt giá ask cho tài nguyên của mình để tối ưu lợi nhuận nhận được qua quá trình đấu giá bằng thuật toán Double Auction. Sau khi giới thiệu cơ sở lý thuyết của đồ án, tôi trình bày phương pháp thực hiện và kết quả. Phần kết quả của đồ án tương đối khả quan: lợi nhuận của các GAISP có xu hướng tăng dần qua các lần training. Với việc tinh chỉnh các tham số, kết quả của đồ án hứa hẹn còn có thể cải thiện thêm trong tương lai.

Lời cảm ơn

Để hoàn thành được đồ án tốt nghiệp này, em xin được gửi lời cảm ơn chân thành nhất đến thầy Nguyễn Công Lượng – giáo viên hướng dẫn của em. Thầy không những đã hỗ trợ cho em rất nhiều trong quá trình làm đồ án, mà còn hỗ trợ em về mặt tinh thần, động viên và cảm thông cho em lúc em bị bệnh. Nhờ đó mà em mới có cơ hội hoàn thành được đồ án này ngày hôm nay. Bên cạnh đó, em cũng cảm ơn những người anh, người em, người bạn trong lab nghiên cứu Phenikaa AI Lab đã luôn tận tâm hỗ trợ và giúp đỡ em hoàn thành đồ án này. Việc được trở thành 1 phần của lab nghiên cứu đã cho em học hỏi được rất nhiều điều. Em cũng cảm ơn các thầy cô giảng viên khoa công nghệ thông tin, đại học Phenikaa đã truyền đạt kiến thức, chỉ bảo em trong suốt hành trình 5 năm học vừa qua. Và lời cảm ơn cuối cùng em muốn dành đến bố mẹ và gia đình em, họ là 1 phần trong hành trình tạo nên con người em từ trước đến nay và cả sau này.

Mặc dù đã rất cố gắng, nhưng vì sự hạn chế của kiến thức, cộng thêm điều kiện sức khỏe gặp vấn đề, đồ án của em không thể tránh khỏi những thiếu sót. Sự góp ý và chỉnh sửa từ các thầy cô phản biện chính là cơ sở để em hoàn thiện thêm về mặt kiến thức sau này. Em xin chân thành cảm ơn!

MỤC LỤC

1. Giới thiệu đề tài nghiên cứu	1
1.1. Đặt vấn đề	1
1.2. Mục tiêu và phạm vi của đề án	1
1.3. Cấu trúc phần còn lại của đề án.	2
2. Tổng quan đề tài nghiên cứu	3
2.1. Giới thiệu về Generative AI.....	3
2.2. Mô hình khuếch tán – 1 mô hình AI tạo sinh	4
2.2.1. Bộ nén ảnh theo nhận thức (Perceptual Image Compressor).....	4
2.2.2. Mô hình khuếch tán trong không gian tiềm ẩn (Latent Diffusion Models) 5	
2.2.3. Cơ chế điều kiện hóa (Conditioning Mechanism)	6
2.3. Mô hình hệ thống (Model System)	7
2.4. Thuật toán Double auction.....	9
2.3.1 . Giới thiệu thuật toán double auction	9
2.3.2. Trình tự của quy trình đấu giá trong Double auction.....	9
2.3.3. Các tính chất mong muốn của 1 cơ chế Double auction hiệu quả.....	10
2.5. Deep Reinforcement Learning.....	11
2.5.1. Tổng quan về các thuật toán học tăng cường	11
2.5.2. Deep Reinforcement learning	14
3. Phương pháp thực hiện nghiên cứu	16
3.1. Cơ chế Double auction	16
3.2. Deep Multi Agent Reinforcement learning	21
4. Kết quả và kết luận.....	23
4.1. Scenario 1 và Scenario 2	23
4.2. Scenario 3	25

Danh mục các từ viết tắt

STT	Ký hiệu chữ viết tắt	Chữ viết đầy đủ
1	AI	Artificial Intelligence
2	GAISP	Generative Artificial Intelligence Service Provider
3	DMARL	Deep Multi Agent Reinforcement learning
4	GAI	Generative Artificial Intelligence
5	PPO	Proximal Policy Optimization
6	MAPPO	Multi Agent Proximal Policy Optimization
7	A2C	Advantage Actor Critic
8	TRPO	Trust Region Policy Optimization

Danh mục hình ảnh và đồ thị

Hình 1: Sơ đồ Stable Diffusion	6
Hình 2: Sơ đồ huấn luyện Agent trong RL	13
Hình 3: Sơ đồ training của 2 kịch bản MAPPO.	22
Hình 4: Lợi nhuận của Auctioneer ở Scenario 1 và Scenario 2	23
Hình 5: Lợi nhuận của GAISPs ở Scenario 1 và Scenario 2	24
Hình 6: Lợi nhuận của Users ở Scenario 1 và Scenario 2	25
Hình 7: Lợi nhuận ở Scenario 3 của Scenario 1 của GAISPs qua các lần training	26
Hình 8: Lợi nhuận ở Scenario 3 của Scenario 2 của GAISPs qua các lần training	27

1. Giới thiệu đề tài nghiên cứu

1.1. Đặt vấn đề

Trong những năm gần đây, AI đã có những bước tiến nhảy vọt và ngày càng hiện diện một cách sâu rộng trong đời sống của con người. Trong đó, GAI đang nổi lên là 1 lĩnh vực đầy tiềm năng và có nhiều ứng dụng thiết thực hỗ trợ công việc và cuộc sống của con người. Đặc biệt từ cuối năm 2022, cùng với sự ra mắt của ChatGPT, “con sói” AI đã hình thành kéo theo sự bùng nổ của làn sóng chạy đua trong việc ứng dụng cũng như phát triển các mô hình GAI giữa các công ty công nghệ trên toàn thế giới.

Việc chạy 1 mô hình sinh ảnh cần rất nhiều tài nguyên tính toán cho việc inference, do đó việc xây dựng mô hình và chạy sinh ảnh trên máy local (máy tính cá nhân) là khó khả thi. Do đó, để thực hiện các nhiệm vụ sinh ảnh, người dùng thường phải tìm đến các mô hình của các công ty công nghệ lớn trên thế giới.

Trong quá trình chạy các mô hình GAI của các công ty này để phục vụ nhu cầu của người tiêu dùng, để có thể sử dụng một cách hiệu quả cơ sở hạ tầng, tài nguyên tính toán (GAISPs), điện năng, ... thì việc có 1 cơ chế phân bổ tài nguyên hiệu quả là rất quan trọng. Các phương pháp hiện nay để giải quyết bài toán này tuy đã được nghiên cứu nhiều ở trên thế giới, nhưng khoảng trống để có thể tiếp tục nghiên cứu và phát triển vẫn còn rất nhiều. Xuất phát từ bài toán thực tiễn đó, trong đồ án này, tôi đã thử nghiệm và chạy thành công việc sử dụng 2 thuật toán để giải quyết bài toán phân bổ tài nguyên trong dịch vụ GAI: thuật toán Double Auction và Deep Reinforcement Learning.

1.2. Mục tiêu và phạm vi của đồ án

Mục tiêu của đồ án là xây dựng mô hình phân bổ tài nguyên và tiếp đến là định giá hiệu quả trong môi trường cung-cầu tương đối phức tạp của dịch

vụ AI tạo sinh, cụ thể ở đây là môi trường của dịch vụ sinh ảnh (image generation), sử dụng thuật toán Double auction và Deep Multi Agent Reinforcement learning. Các mục tiêu cụ thể của đề án như sau:

- Mô hình hóa bài toán phân bổ tài nguyên trong dịch vụ sinh ảnh để áp dụng các thuật toán double auction và Deep Reinforcement learning để tối ưu hóa tổng lợi nhuận (total utility) của các bên tham gia.
- Thiết kế thuật toán double auction để ghép nối các task của Users với GAISPs, đồng thời sử dụng được kết quả để huấn luyện mô hình DMARL.
- Ứng dụng thuật toán DMARL để giúp GAISPs tìm ra chiến lược đặt giá tối ưu.
- Thực nghiệm và đánh giá hiệu năng mô hình trên môi trường mô phỏng.

Phạm vi thực hiện của đề án như sau:

- Số lượng agent, GAISPs hữu hạn và xác định trước.
- Giới hạn việc triển khai thuật toán ở môi trường mô phỏng với tập dữ liệu kiểm tra được tạo ngẫu nhiên, không triển khai hệ thống trên môi trường thực tế.

1.3. Cấu trúc phần còn lại của đề án.

Phần còn lại của đề án được tổ chức như sau:

- Chương 2: chương này giới thiệu các khái niệm lý thuyết nền tảng của nghiên cứu, bao gồm các khái niệm về mô hình khuếch tán, thuật toán Double auction, Deep Reinforcement learning, Deep Reinforcement learning, Multi Agent Proximal Policy Optimization và mô hình hệ thống.
- Chương 3: đây là chương trọng tâm, trình bày cách tôi sử dụng thuật toán Double auction và Deep Multi Agent Reinforcement learning vào trong bài toán cụ thể của đề án.
- Chương 4: Nêu ra những kết quả chạy thực nghiệm và kết luận.

2. Tổng quan đề tài nghiên cứu

2.1. Giới thiệu về Generative AI

Giới thiệu chung về Generative AI Generative AI (Trí tuệ nhân tạo tạo sinh) là một lĩnh vực của trí tuệ nhân tạo tập trung vào việc tạo ra dữ liệu mới có đặc điểm tương tự với dữ liệu huấn luyện ban đầu. Thay vì chỉ phân loại hoặc dự đoán, các mô hình Generative AI có khả năng "sáng tạo" ra văn bản, hình ảnh, âm thanh, mã lập trình, và nhiều định dạng dữ liệu khác.

Các mô hình Generative AI học từ phân phối xác suất của dữ liệu đầu vào. Khi đã học được phân phối này, mô hình có thể lấy mẫu (sampling) để sinh ra dữ liệu mới có phân bố tương tự. Một số ví dụ về mô hình tạo sinh:

- Generative Adversarial Networks (GANs)
- Variational Autoencoders (VAEs)
- Autoregressive models (như GPT)
- Diffusion Models

Các loại mô hình Generative AI phổ biến

- **GANs (Generative Adversarial Networks):** Gồm hai mạng neural đối kháng nhau: Generator cố gắng tạo ra dữ liệu giống thật, trong khi Discriminator cố gắng phân biệt dữ liệu thật và dữ liệu giả.
- **VAEs (Variational Autoencoders):** Là dạng autoencoder có tính chất xác suất, sử dụng phân phối tiềm ẩn để sinh dữ liệu mới.
- **Autoregressive models:** Dựa vào chuỗi thời gian, tạo ra từng phần tử tiếp theo dựa vào các phần tử trước. GPT (Generative Pre-trained Transformer) là ví dụ nổi bật.

- **Diffusion Models:** Là mô hình học cách khôi phục dữ liệu từ nhiễu. Mô hình học cách đảo ngược quá trình thêm nhiễu vào dữ liệu.

Generative AI có mặt trong nhiều lĩnh vực:

- **Xử lý ngôn ngữ tự nhiên (NLP):** Sinh văn bản, dịch máy, tóm tắt văn bản.
- **Thị giác máy tính:** Tạo ảnh, video, phục hồi ảnh cũ, siêu phân giải.
- **Y sinh học:** Thiết kế protein, phân tử thuốc mới.
- **Trí tuệ nhân tạo sáng tạo:** Vẽ tranh, sáng tác nhạc, làm thơ.

2.2. Mô hình khuếch tán – 1 mô hình AI tạo sinh

Mô hình khuếch tán (Diffusion Model) của chúng tôi bao gồm ba thành phần chính: bộ nén ảnh theo nhận thức (perceptual image compressor), mô hình khuếch tán trong không gian tiềm ẩn (latent diffusion model) và cơ chế điều kiện hóa (conditioning mechanism). Bộ nén ảnh sẽ trích xuất các phần quan trọng nhất của dữ liệu vào không gian tiềm ẩn, trong khi mô hình khuếch tán thực hiện quá trình khuếch tán trên biểu diễn tiềm ẩn đó. Cơ chế điều kiện hóa cung cấp các chỉ dẫn có điều kiện cho toàn bộ quy trình sinh ảnh, ví dụ như văn bản đầu vào.

2.2.1. Bộ nén ảnh theo nhận thức (Perceptual Image Compressor)

Mô hình nén theo nhận thức của chúng tôi gồm một cấu trúc autoencoder (gồm encoder và decoder). Với một ảnh $x \in \mathbb{R}^{H \times W \times 3}$ ở không gian RGB, encoder ξ mã hóa ảnh thành biểu diễn tiềm ẩn $z = \xi(x)$, và decoder D tái tạo lại ảnh từ biểu diễn tiềm ẩn đó, tạo thành $\tilde{x} = D(z) = D(\xi(x))$, với $z \in \mathbb{R}^{h \times w \times 3}$. Đáng chú ý, encoder giảm kích thước ảnh theo tỷ lệ $f = H/h = W/w$.

2.2.2. Mô hình khuếch tán trong không gian tiềm ẩn (Latent Diffusion Models)

Mô hình khuếch tán có thể được mô tả là mô hình xác suất nhằm học phân phối dữ liệu $p(x)$ bằng cách dần loại bỏ nhiễu từ một biến tuân theo phân phối chuẩn, tương ứng với việc học quá trình ngược lại của một chuỗi Markov cố định dài T . Trong sinh ảnh, các mô hình hiệu quả nhất dựa trên một biến thể có trọng số lại của ràng buộc dưới theo phương sai (variational lower bound) của $p(x)$.

Các mô hình này có thể được hiểu là một chuỗi có trọng số đều gồm autoencoder loại bỏ nhiễu $\epsilon_\theta(x_t, t)$, được huấn luyện để dự đoán phiên bản đã loại nhiễu của đầu vào x_t , trong đó x_t là phiên bản bị nhiễu của x , và $t \in \{1, \dots, T\}$. Quá trình tiến (forward process) trong các mô hình này là một chuỗi Markov cố định liên tục thêm nhiễu Gaussian vào dữ liệu:

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{(1 - \beta_t)}x_{t-1}, \beta_t I) \quad (1)$$

trong đó β_t là một số dương nhỏ điều khiển lượng nhiễu tại mỗi bước. Chuỗi tiến này biến đổi dữ liệu gốc x_0 thành phiên bản bị nhiễu x_T . Quá trình ngược (reverse process) bắt đầu từ một biến nhiễu và loại bỏ nhiễu dần dần để khôi phục dữ liệu gốc. Quá trình này được mô hình hóa như sau:


$$p_\theta(x_{t-1} | x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)) \quad (2)$$

trong đó μ_θ và Σ_θ được dự đoán bởi mạng nơ-ron.

Mục tiêu huấn luyện của mô hình khuếch tán thông thường là giảm sai lệch giữa các nhiễu thực tế trong quá trình tiến và nhiễu dự đoán trong quá trình ngược:

$$L_{DM} = \mathbb{E}_{x, \epsilon \sim \mathcal{N}(0, I), t} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2] \quad (3)$$

trong đó ϵ là nhiễu lấy từ phân phối chuẩn, và t được chọn ngẫu nhiên từ tập $\{1, \dots, T\}$. Khi mô hình học được cách dự đoán và loại bỏ nhiễu một cách chính xác, nó có thể học được cấu trúc và phân phối cơ bản của dữ liệu gốc.



Hình 1: Sơ đồ Stable Diffusion

Hãy nhớ rằng bộ nén ảnh ở đây bao gồm $\mathcal{E}$ và $\mathcal{D}$. Thay vì khuếch tán trực tiếp trên ảnh gốc có kích thước cao, tôi thực hiện khuếch tán trên không gian tiềm ẩn có kích thước nhỏ hơn nhiều, giúp huấn luyện hiệu quả hơn về mặt tính toán và chỉ giữ lại thông tin ngữ nghĩa quan trọng. Tôi sử dụng cấu trúc U-Net [1] nổi tiếng, từ đó biến mục tiêu học thành:

$$L_{LDM} = \mathbb{E}_{\xi(x), \epsilon \sim \mathcal{N}(0,1), t_l} [\|\epsilon - \epsilon_\theta(z_t, t)\|^2] \quad (4)$$

trong đó $\epsilon_\theta(o, t)$ là U-Net phụ thuộc thời gian, và z_t có thể dễ dàng thu được từ ξ trong quá trình huấn luyện.

Về U-Net [1]: đây là mô hình CNN được thiết kế đặc biệt cho các tác vụ xử lý ảnh. Cấu trúc chữ U gồm một encoder giảm dần độ phân giải để trích xuất đặc trưng, và một decoder tăng dần độ phân giải để tái tạo lại ảnh đầu ra. Các kết nối skip giữa các lớp tương ứng của encoder và decoder giúp bảo toàn thông tin không gian, từ đó đạt được kết quả loại bỏ nhiễu chính xác.

2.2.3. Cơ chế điều kiện hóa (Conditioning Mechanism)

Các mô hình khuếch tán đã chứng minh khả năng mô hình hóa phân phối có điều kiện [2] $p(z|y)$ thông qua autoencoder loại nhiễu có điều kiện $\epsilon_\theta(z_t, t, y)$. Tôi tăng tính linh hoạt của mô hình khuếch tán tiềm ẩn bằng cách

chỉnh sửa cấu trúc U-Net với cơ chế cross-attention. Đầu vào điều kiện y có thể là văn bản, bản đồ ngữ nghĩa hoặc một hình ảnh khác,...

Vì y có thể đến từ nhiều miền khác nhau (đa phương thức), tôi giới thiệu một encoder chuyên biệt theo miền τ_θ để biến đổi y thành một vector trung gian $\tau_\theta(y) \in \mathbb{R}^{m \times d_r}$ sau đó ánh xạ đến các lớp trung gian trong U-Net thông qua cơ chế attention chéo: [3], [4]

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d}}\right) \quad (5)$$

với:

$$Q = W_Q^{(i)} \cdot \varphi_i(z_t)$$

$$K = W_K^{(i)} \cdot \tau_\theta(y),$$

$$V = W_V^{(i)} \cdot \tau_\theta(y)$$

Ở đây, $\varphi_i(z_t) \in \mathbb{R}^{N \times d_\varepsilon^i}$ là biểu diễn trung gian (làm phẳng) của U-Net, và các ma trận $W_Q^{(i)}$, $W_K^{(i)}$, $W_V^{(i)}$ là các ma trận chiếu học được.

Tôi chọn kiến trúc CLIP [5] cho encoder τ_θ . Mục tiêu tối ưu của mô hình khuếch tán tiềm ẩn có điều kiện trở thành:

$$L_{LDM} = \mathbb{E}_{\xi(x), y, \varepsilon \sim \mathcal{N}(0, I), t} [\|\varepsilon - \epsilon_\theta(z_t, t, \tau_\theta(y))\|^2] \quad (6)$$

trong đó τ_θ và ϵ_θ được tối ưu đồng thời.

2.3. Mô hình hệ thống (Model System)

Đề án này xét một kịch bản có một tập người dùng N và một tập các nhà cung cấp dịch vụ AI sinh (GAISP) M . Mỗi người dùng n có một tập các tác vụ GAI, ký hiệu N_n gồm N_n tác vụ. Chúng tôi định nghĩa tác vụ GAI $i \in N_n$ của người dùng n là:

$$\text{GAI}_{n,i} = \{ S_{n,i}^{in,img}, S_{n,i}^{in,prompt}, \kappa_n \}$$

trong đó $S_{n,i}^{in,img}$, và $S_{n,i}^{in,prompt}$ lần lượt là kích thước dữ liệu (tính bằng bit) của cặp ảnh–prompt đầu vào dùng để dẫn hướng mô hình GAI cho tác vụ i của người dùng n , và $\kappa_n \in [0,1]$ biểu thị mức độ tương đồng giữa ảnh đầu vào và ảnh sinh ra [6]. Số bước khử nhiễu tối đa mà các GAISP hỗ trợ được ký hiệu r_m^{denoi} . Với mỗi tác vụ $GAI_{n,i}$, số bước khử nhiễu cần thiết λ_n được tính:

$$\lambda_n = \kappa_n r_m^{denoi}. \quad (7)$$

Về nguyên tắc, suy luận (inference) trên mô hình khuếch tán đòi hỏi tài nguyên tính toán đáng kể [7]. Người dùng muốn thực hiện suy luận với ảnh và prompt nhưng không đủ tài nguyên, do đó họ cần dựa vào hỗ trợ tính toán và truyền thông do GAISP cung cấp. Mỗi người dùng gửi thông tin cần thiết (cặp ảnh-prompt) tới GAISP tương ứng để thực hiện tác vụ, sau đó GAISP trả kết quả về cho người dùng.

1) Chi phí tài nguyên tính toán: Chi phí tính toán cho tác vụ i của người dùng n (ký hiệu $F_{n,i}$) phụ thuộc vào số phép tính mà mô hình yêu cầu. Thước đo phổ biến là số phép tính dấu chấm động (FLOPs). Giả sử một trường hợp suy luận cơ sở có kích thước ảnh đầu vào $H_0 \times W_0$; khi đó F_0^ξ , F_0^ε , F_0^τ và F_0^D lần lượt là số FLOPs của encoder, mỗi khối U-Net khử nhiễu, cơ chế điều kiện và decoder. Với mỗi tác vụ, số FLOPs cần thiết được xấp xỉ:

$$F_{n,i} = \{ H_{n,i} W_{n,i} \} / \{ H_0 W_0 \} (F_0^\xi + F_0^D) + \lambda_n F_0^\varepsilon + F_0^\tau. \quad (8)$$

trong đó $H_{n,i}$, $W_{n,i}$ là chiều cao và chiều rộng của ảnh trong tác vụ.

2) Chi phí tài nguyên truyền tải: Gọi $S_{n,i}^{comm}$, là chi phí truyền tải của tác vụ i (tính bằng bit), được định nghĩa là tổng kích thước dữ liệu truyền trong quá trình thực thi – gồm dữ liệu người dùng gửi đi và ảnh sinh GAISP trả về. Kích thước dữ liệu đầu vào là:

$$S_{n,i}^{in} = S_{n,i}^{in,img} + S_{n,i}^{in,prompt}. \quad (9)$$

Mô hình GAI tạo ra ảnh bằng với kích thước ảnh đầu vào, nên kích thước ảnh đầu ra được tính:

$$s_{n,i}^{out,img} = H_{n,i} \times W_{n,i} \times C \times b. \quad (10)$$

trong đó C là số kênh màu và b là độ sâu bit (bit trên pixel).

Do đó:

$$s_{n,i}^{comm} = s_{n,i}^{in} + s_{n,i}^{out,img}. \quad (11)$$

Ngoài ra, GAISP phải cấp phát bộ nhớ đáng kể cho mỗi tác vụ. Giới hạn bộ nhớ khiến một GAISP chỉ xử lý đồng thời một số tác vụ nhất định. Giả sử GAISP m có thể xử lý tối đa M_m tác vụ cùng lúc, ta có ràng buộc:

$$N_n \leq M_m. \quad (12)$$

2.4. Thuật toán Double auction

2.3.1. Giới thiệu thuật toán double auction

Double auction là 1 cơ chế kinh tế được thiết kế và sử dụng cho việc mua bán hàng hóa hoặc tài nguyên giữa nhiều người mua và nhiều người bán. Không giống như cơ chế đấu giá 1 chiều, nơi mà chỉ có 1 người mua và nhiều người bán hoặc ngược lại, trong double auction, nhiều người mua và bán cùng đưa ra mức giá riêng của họ. Đây là 1 cơ chế đặc biệt hiệu quả trong môi trường có nhiều người mua và bán cùng tham gia, ví dụ như thị trường chứng khoán, thị trường năng lượng, và trong báo cáo này chúng ta sẽ tìm hiểu về ghép nối đấu giá trong quản lý tài nguyên trong dịch vụ tạo sinh hình ảnh bằng AI. Trong double auction, 1 bên trung gian sẽ đứng ra làm nhiệm vụ đấu giá và thường được xem như “đấu giá viên” (auctioneer). Sở dĩ thuật toán double auction là 1 thuật toán hiệu quả và được sử dụng rộng rãi là do nó sở hữu nhiều tính chất và đặc điểm nổi trội mà chúng ta sẽ tìm hiểu ở những mục sau.

2.3.2. Trình tự của quy trình đấu giá trong Double auction

Thuật toán Double auction có rất nhiều biến thể, và chúng ta sẽ cùng tìm hiểu về thuật toán Double auction tiêu chuẩn. Ở phiên bản tiêu chuẩn của nó, thuật toán Double auction gồm 3 thành phần:

- Người mua (Buyers): Đưa ra giá thầu (bids) và các yêu cầu khác nếu có (như lượng tài nguyên yêu cầu cần thiết).
- Người bán (Sellers): Đưa ra giá bán (asks) và các chỉ số về tài nguyên khác (như lượng tài nguyên có sẵn).
- Đấu giá viên (Auctioneer): Đóng vai trò trung gian thu thập các bids và asks mà buyers và sellers submit, sau đó xác định giá giao dịch và thực hiện việc matching các buyer và seller đủ điều kiện về giá.

Trình tự đấu giá trong thuật toán Double auction tiêu chuẩn:

1. Auctioneer thu thập tất cả bids và asks mà buyers và sellers submit.
2. Auctioneer sắp xếp các bid theo thứ tự giảm dần và các ask theo thứ tự tăng dần.
3. Xác định chỉ số k sao cho k là chỉ số lớn nhất thỏa mãn phần tử thứ k của tập bid lớn hơn hoặc bằng phần tử thứ k của tập ask.
4. Tiến hành matching giữa các bid và ask thỏa mãn $\text{bid} \geq \text{ask}$, theo thứ tự lần lượt tương ứng các phần tử trong tập bid và ask từ 1 đến k .
Nghĩa là phần tử thứ i trong tập bid ghép nối với phần tử thứ i trong tập ask, với $1 \leq i \leq k$.
5. Xác định giá giao dịch cho mỗi người mua và người bán.

2.3.3. Các tính chất mong muốn của 1 cơ chế Double auction hiệu quả.

Một cơ chế Double auction tốt phải cố gắng đạt được càng nhiều càng tốt trong 4 thuộc tính sau đây, tuy nhiên việc đạt được cả 4 thuộc tính là điều không bao giờ xảy ra, theo định lý Myerson-Satterthwaite. Các thuộc tính đó bao gồm:

- Tính hợp lý cá nhân (IR – Individual Rationality): không ai bị lỗ khi tham gia vào quá trình đấu giá. Theo đó, lợi ích thấp nhất mà mỗi người mua và người bán thu được khi tham gia đấu giá là 0.

- Ngân sách cân bằng (BB – Budget Balance): tính chất này có 2 phiên bản:
 - + Ngân sách cân bằng mạnh mẽ (SBB – Strong Budget Balance): đấu giá viên không mất hoặc kiếm được tiền, mà tất cả giao dịch tiền tệ đều được thực hiện trực tiếp giữa người mua và người bán.
 - + Ngân sách cân bằng yếu (WBB – Weak Budget Balance): đấu giá viên không mất tiền, nhưng có thể kiếm được tiền. Đa phần các cơ chế đấu giá hiện đại thuộc loại này.
- Khả năng khuyến khích trung thực (IC – Incentive Compatibility): tính chất này cũng tồn tại 2 phiên bản:
 - + Phiên bản mạnh mẽ hơn quy định rằng việc báo giá trị trung thực phải là chiến lược xuyên suốt cho tất cả các người chơi. Nghĩa là, một người chơi không thể có được lợi nhuận bằng cách theo dõi những người chơi khác và cố gắng tìm ra một định giá khác với giá trị thực của họ.
 - + Phiên bản yếu hơn phát biểu rằng tồn tại 1 cân bằng Nash trong đó tất cả những người chơi báo cáo định giá thực của họ. Tức là nếu tất cả người chơi ngoại trừ chỉ 1 người báo cáo trung thực, thì tốt nhất người còn lại này cũng nên trung thực.
- Hiệu quả kinh tế (Economic Efficiency): tổng lợi ích kinh tế của tất cả các bên tham gia phải là tốt nhất có thể. Điều này nghĩa là tất cả các mặt hàng sẽ nằm trong tay những người coi trọng chúng nhất.

2.5. Deep Reinforcement Learning

2.5.1. Tổng quan về các thuật toán học tăng cường


Học tăng cường là 1 nhánh của học máy – trong đó 1 tác nhân học 1 chính sách tối ưu để tối đa hóa tổng phần thưởng tích lũy trong dài hạn [8]. Để làm được điều này, tác nhân sẽ học thông qua hàm giá trị (value-based), hoặc trực tiếp qua hàm chính sách (policy-based), hoặc kết hợp cả 2. Về mặt

tổng quan, tác nhân sẽ tương tác với môi trường và nhận lại phần thưởng, từ đó học được mức độ “tốt – xấu” của mỗi hành động và điều chỉnh chính sách để tối đa hóa phần thưởng trong tương lai. Bài toán học tăng cường thường được mô hình hóa dưới dạng quá trình quyết định Markov (Markov Decision Process – MDP), với các thành phần:

- Trạng thái (State): các thông tin về trạng thái hiện tại của môi trường
- Hành động (Action): lựa chọn hành động của tác nhân tại mỗi trạng thái
- Phần thưởng (Reward): Phần thưởng mà tác nhân nhận được khi thực hiện 1 hành động.
- Chính sách (Policy): quy tắc quyết định hành động khi ở các trạng thái khác nhau.

Các nhóm thuật toán Reinforcement learning khác nhau:

- Nhóm thuật toán dựa trên giá trị (Value-Based Methods): Mục tiêu của nhóm thuật toán này là ước lượng 1 hàm giá trị $Q(a | s)$ – hàm ước lượng tổng phần thưởng mà tác nhân sẽ nhận được nếu lựa chọn action a tại state s . Sau đó chính sách tối ưu sẽ là lựa chọn action có giá trị Q lớn nhất tại mỗi trạng thái. Các thuật toán tiêu biểu bao gồm:
 - + Q-learning: Sử dụng phương trình Bell-man để cập nhật giá trị Q , và là 1 thuật toán off-policy vì trong công thức cập nhật giá trị Q của mình, Q-learning luôn lựa chọn phần thưởng có giá trị cao nhất.



Hình 2: Sơ đồ huấn luyện Agent trong RL

+ SARSA: tương tự như Q-learning, tuy nhiên nó là 1 thuật toán on-policy, vì trong công thức cập nhật giá trị Q của mình, nó sử dụng cùng 1 chính sách giống như khi lựa chọn hành động a.

+ Deep Q-learning: mở rộng Q-learning bằng việc kết hợp với các mạng nơ ron sâu để xấp xỉ hàm Q, hiệu quả trong môi trường có không gian trạng thái lớn, như hình ảnh, ...

- Nhóm thuật toán dựa trên chính sách (policy-based methods): các thuật toán này học trực tiếp chính sách dựa trên gradient để tối ưu 1 hàm có tham số là các tham số của mạng chính sách (policy network). Các thuật toán tiêu biểu bao gồm:
 - + REINFORCE: cập nhật chính sách dựa trên phần thưởng thực tế.
 - + Actor-critic: sử dụng 1 hàm giá trị trạng thái (state value function) để làm căn cứ đánh giá mức độ “tốt-xấu” của hành động hiện tại, từ đó cập nhật chính sách để điều chỉnh xác suất lựa chọn hành động đó trong tương lai.

- + TRPO (Trust Region Policy Optimization): Nhằm cùng mục đích như actor-critic, nhưng TRPO có thêm ràng buộc đảm bảo sự ổn định trong quá trình học.
- + PPO (Proximal Policy Optimization): thuật toán phổ biến nhất trong họ các thuật toán policy-based methods, với cùng 1 cách huấn luyện như TRPO nhưng có hàm mục tiêu đơn giản giúp cho việc triển khai thuật toán được dễ dàng và hiệu quả mẫu cao hơn.
- Nhóm thuật toán kết hợp:
 - + A2C/A3C: sử dụng lợi thế (Advantage) thay vì giá trị tuyệt đối để cập nhật chính sách
 - + DDPG, TD3: là nhóm thuật toán dùng cho không gian hành động liên tục.

2.5.2. Deep Reinforcement learning

2.4.2.1. Giới thiệu về học tăng cường sâu

Học Tăng cường Sâu (DRL) là một lĩnh vực của học máy kết hợp giữa học tăng cường (Reinforcement Learning - RL) và học sâu (Deep Learning) để giải quyết các bài toán ra quyết định. Trong DRL, tác nhân (agent) học cách đưa ra chuỗi quyết định bằng cách tương tác với môi trường nhằm tối đa hóa phần thưởng tích lũy. DRL đã được áp dụng thành công trong nhiều lĩnh vực như robot, xe tự hành, y tế, tài chính và trò chơi (ví dụ: AlphaGo, ...).

2.4.2.2. Học Sâu trong Học Tăng cường

Các phương pháp RL truyền thống gặp khó khăn khi xử lý không gian trạng thái lớn hoặc liên tục. Học sâu khắc phục điều này bằng cách sử dụng mạng nơ-ron để xấp xỉ các hàm. Ví dụ, Deep Q-Network (DQN) sử dụng mạng nơ-ron tích chập (CNN) để ước lượng giá trị hành động (Q-value) từ đầu vào ảnh thô trong các môi trường như trò chơi Atari.

2.4.2.3. Các Thuật toán Chính trong DRL

- Deep Q-Network (DQN): Sử dụng mạng nơ-ron để xấp xỉ hàm giá trị Q. Được giới thiệu bởi DeepMind, DQN sử dụng các kỹ thuật như phát lại kinh nghiệm (experience replay) và mạng mục tiêu (target network) để ổn định quá trình huấn luyện.
- Double DQN: Giải quyết vấn đề đánh giá quá cao trong DQN bằng cách sử dụng hai mạng để chọn và đánh giá hành động.
- Dueling DQN: Tách việc ước lượng giá trị trạng thái và hàm lợi thế.
- Phương pháp Gradient Chính sách (Policy Gradient): Học trực tiếp chính sách được tham số hóa. Ví dụ như REINFORCE và Actor-Critic.
- Proximal Policy Optimization (PPO): Một thuật toán tối ưu chính sách ổn định và hiệu quả sử dụng hàm mục tiêu được cắt ngưỡng.
- Deep Deterministic Policy Gradient (DDPG): Mở rộng phương pháp Actor-Critic cho không gian hành động liên tục bằng chính sách xác định.
- Soft Actor-Critic (SAC): Thêm yếu tố điều chuẩn entropy để khuyến khích khám phá.

2.4.2.4. Khám phá và Khai thác

Một thách thức cốt lõi trong DRL là cân bằng giữa khám phá (thử hành động mới) và khai thác (chọn hành động mang lại phần thưởng cao). Các kỹ thuật như chiến lược ϵ -greedy, cộng điểm entropy và học dựa trên sự tò mò được sử dụng để xử lý vấn đề này.

2.4.2.5. Các Thách thức trong DRL

Hiệu quả mẫu thấp: DRL thường yêu cầu lượng lớn dữ liệu tương tác với môi trường.

- Độ ổn định và hội tụ: Việc huấn luyện mạng nơ-ron với RL thường không ổn định do dữ liệu tương quan và môi trường thay đổi.
- Phân bổ phần thưởng: Xác định hành động nào dẫn đến phần thưởng trong các tác vụ dài hạn là điều khó khăn.
- Khả năng tổng quát hóa: Các tác nhân DRL thường bị quá khớp với môi trường cụ thể và khó áp dụng cho môi trường mới.

2.4.2.6. Ứng dụng của DRL

DRL có nhiều ứng dụng thực tế hiện đã được triển khai trên nhiều lĩnh vực và thể hiện được mức độ hiệu quả nhất định:

- Trò chơi: DRL đạt hiệu suất vượt trội trong các trò chơi Atari, Go, Dota 2 và StarCraft II.
- Robot: DRL giúp robot học các kỹ năng vận động phức tạp như nắm bắt, di chuyển.
- Y tế: Lập kế hoạch điều trị cá nhân hóa, khám phá thuốc.
- Tài chính: Giao dịch thuật toán và quản lý danh mục đầu tư.
- Hệ thống thông minh: Xe tự hành, điều khiển lưới điện thông minh, tự động hóa công nghiệp.

3. Phương pháp thực hiện nghiên cứu

3.1. Cơ chế Double auction

Trong một môi trường động với nhiều người dùng và GAISP, yếu tố cạnh tranh đóng vai trò then chốt trong việc phân bổ tài nguyên một cách hiệu quả. Người dùng cạnh tranh để giành lấy tài nguyên tính toán và truyền tải nhằm thực hiện các tác vụ AI tạo sinh, trong khi các GAISP hướng tới việc tối ưu hóa việc sử dụng tài nguyên và tối đa hóa lợi nhuận. Để mô hình hóa tương tác này, tôi áp dụng thị trường đấu giá hai chiều, trong đó người dùng đóng vai trò người mua cạnh tranh để có được tài nguyên, còn GAISP là người bán cung cấp tài nguyên.

- Người dùng (Người mua):

Người dùng $n \in N$ xác định giá chào mua (hoặc bid) $p_{n,i}^b$ cho tác vụ i , tức là người dùng n sẵn sàng trả tối đa $p_{n,i}^b$ để một GAISP nào đó cung cấp tài nguyên thực hiện tác vụ này. Người dùng n cần xử lý tổng cộng q_n^b tác vụ. Giá bid cho tác vụ i và tổng nhu cầu tài nguyên của người dùng n được biểu diễn như sau:

$$p_{n,i}^b = \xi_n^b \cdot F_{n,i}^{comp} + \eta_n^b \cdot S_{n,i}^{comm} \quad (13a)$$

$$q_n^b = N_n \quad (13b)$$

Trong đó:

ξ_n^b, η_n^b là đơn giá mà người dùng sẵn sàng chi trả cho tài nguyên tính toán và truyền tải;

$F_{n,i}^{comp}$: số FLOPs cần thiết cho tác vụ;

$s_{n,i}^{comm}$: chi phí tài nguyên truyền thông cho tác vụ.

- GAISP (Người bán):

Mỗi GAISP $m \in M$ xác định giá chào bán (ask) $p_{m,j}^s$ cho tác vụ j trong tổng số

M_m tác vụ mà GAISP m cung cấp, cũng như lượng tài nguyên tổng thể q_m^s .

GAISP cung cấp tài nguyên tính toán và truyền tải cho người dùng và nhận thanh toán để đổi lại.

Ký hiệu:

- r_m^{comp} : lượng tài nguyên tính toán GAISP có thể cung cấp;

- r_m^{denoi} : số bước khử nhiễu có thể thực hiện;

- r_m^{comm} : lượng tài nguyên truyền tải sẵn có.

GAISP tính giá chào bán như sau:

$$p_{m,j}^s = \xi_m^s \cdot r_m^{comp} + \zeta_m^s \cdot r_m^{denoi} + \eta_m^s \cdot r_m^{comm} \quad (14a)$$

$$q_m^s = M_m \quad (14b)$$

Trong đó $\xi_m^s, \zeta_m^s, \eta_m^s$ là đơn giá của GAISP cho tài nguyên tính toán, bước khử nhiễu, và truyền tải tương ứng.

- Đấu giá viên (Auctioneer):

Đấu giá viên là một thực thể trung tâm, quản lý toàn bộ quá trình đấu giá, đảm bảo công bằng, minh bạch và phân bổ tài nguyên hiệu quả. Cụ thể, đấu giá viên sẽ thu thập các giá chào mua từ người dùng và giá chào bán từ GAISP, sau đó xác định cách ghép cặp tối ưu giữa người dùng và GAISP sao cho đáp ứng nhu cầu người dùng và tối đa hóa lợi ích của người bán.

Ký hiệu:

- W_b : tập hợp các giá bid thắng cuộc của người mua;
- $u_{n,i}$: lợi ích (utility) của tác vụ i của người dùng n , được xác định như sau:

$$u_{n,i} = \begin{cases} p_{n,i}^b - p_{n,i}^M & \text{nếu } p_{n,i}^b \in W_b \\ 0 & \text{nếu ngược lại.} \end{cases} \quad (15)$$

Trong đó $p_{n,i}^M$ là giá thanh toán thực tế của tác vụ i của người dùng n .

- W_s : tập hợp các giá chào bán được ghép thành công từ người bán.
- Lợi ích của tác vụ j của người bán m là:

$$u_{m,j} = \begin{cases} \gamma_{m,j} - p_{m,j}^s & \text{nếu } \gamma_{m,j} \in W_s \\ 0 & \text{nếu ngược lại.} \end{cases} \quad (16)$$

Trong đó $\gamma_{m,j}$ là giá thanh toán mà GAISP nhận được cho tác vụ j .

- Lợi ích của đấu giá viên là chênh lệch giữa tổng số tiền thu được từ người dùng và tổng số tiền trả cho GAISP:

$$u_a = \sum_{p_{n,i}^M \in W_b} (p_{n,i}^M) - \sum_{\gamma_{m,j} \in W_s} (\gamma_{m,j}) \quad (17)$$

Mục tiêu của cơ chế đấu giá hai chiều này là:

- Ghép cặp người mua (người dùng) và người bán (GAISP);
- Xác định giá thanh toán cho cả hai bên;
- Phân bổ tài nguyên hiệu quả trong các tác vụ AI tạo sinh.

Bài toán được mô hình hóa dưới dạng tối ưu:

$$\max u_a$$

với các ràng buộc:

$$\begin{aligned} p_{n,i}^b &\geq p_{n,i}^M & \forall n \in N \\ p_{m,j}^s &\leq \gamma_{m,j} & \forall m \in M \\ p_{n,i}^b - p_{n,i}^M &\geq p_{n,i}^{b'} - p_{n,i}^{M'} & \forall n \in N \\ \gamma_{m,j} - p_{m,j}^s &\geq \gamma'_{m,j} - p_{m,j}^{s'} & \forall m \in M \end{aligned} \quad (18)$$

Trong đó:

- $p_{n,i}^b$ và $p_{m,j}^s$ là bid và ask trung thực;
- $p_{n,i}^M$ và $\gamma_{m,j}$ là giá thanh toán thực tế;
- $p_{n,i}^{b'}$, $p_{m,j}^{s'}$, $p_{n,i}^{M'}$, $\gamma'_{m,j}$ là các bid/ask không trung thực.

Dựa trên nhu cầu thực tế của người dùng dịch vụ, tôi đã thiết kế 2 kịch bản cho thuật toán Double auction:

- Kịch bản 1: Người dùng yêu cầu đủ tài nguyên cho tất cả các task mà họ yêu cầu. Kịch bản này phù hợp với nhiều trường hợp sử dụng trong thực tế, ví dụ khi 1 họa sĩ cần vẽ tranh, nếu thực hiện các bức tranh trong cùng 1 chương trình nhiều câu lệnh, các bức tranh sẽ mất đi sự nhất quán cần thiết về

mặt bối cảnh, tạo hình nhân vật, ... do đó người dùng yêu cầu khi gửi lệnh tạo ảnh thì GAISP phải có đủ tài nguyên để sinh tất cả các ảnh trong 1 câu lệnh.

- Kịch bản 2: Người dùng không yêu cầu đủ tài nguyên cho tất cả các task mà họ yêu cầu. Đây là kịch bản phù hợp với đa số trường hợp sử dụng trong thực tế.

Chi tiết về 2 thuật toán như sau:

1) : Scenario 1: Each user requires sufficient resources for all of its tasks to be successfully matched by the auctioneer.

Algorithm 1 Algorithm for Double Auction Mechanism - Scenario 1

```

1: INPUT:
2: Set of users:  $\mathcal{N} = \{1, \dots, n, \dots, N\}$ 
3: Set of GAISPs:  $\mathcal{M} = \{1, \dots, m, \dots, M\}$ 
4: Set of GAI tasks of user  $n$ :  $\mathcal{N}_n = \{1, \dots, i, \dots, N_n\}$ 
5: The similarity level between the input and the generated image of user  $n$ :  $\kappa_n, \forall n \in \mathcal{N}$ 
6: Height and weight of the image  $i$  of user  $n$ :  $H_{n,i}, W_{n,i}, \forall n \in \mathcal{N}, \forall i \in \mathcal{N}_n$ 
7: Data size of input image  $i$  of user  $n$ :  $s_{n,i}^{\text{in,img}}$ 
8: Data size of input prompt corresponding to image  $i$  of user  $n$ :  $s_{n,i}^{\text{in,prompt}}$ 
9: The maximum number of tasks that GAISP  $m$  can process simultaneously:  $M_m, \forall m \in \mathcal{M}$ 
10: Unit prices that the buyers are willing to pay for computation and communication resources:  $\xi_n, \eta_n^b$ 
11: Amounts and unit costs of resources of sellers:  $r_m^{\text{comp}}, r_m^{\text{comm}}, r_m^{\text{denoi}}, \xi_m^s, \eta_m^s, \zeta_m^s, \forall m \in \mathcal{M}$ 
12: OUTPUT:
13: Matching dictionary:

$$M = \left\{ ((i, n), (j, m)) := \text{task } i \text{ of user } n \right. \\ \left. \text{has been matched with task } j \text{ of GAISP } m \right\}$$

14: Payment price of task  $i$  of buyer  $n$ :  $p_{n,i}^m, \forall n \in \mathcal{N}, \forall i \in \mathcal{N}_n$ 
15: Selling price for task  $j$  of GAISP  $m$ :  $\gamma_{m,j}, \forall m \in \mathcal{M}, \forall j \in M_m$ 
16: ALGORITHM:
17: Initialize the matching dictionary,  $M = \{\}$ 
18: User  $n$  computes the number of denoising steps required by each task,  $\lambda_n$ , based on (7)
19: User  $n$  computes the number of FLOPs required for the inference of each task,  $F_{n,i}$  based on (8)
20: User  $n$  computes the communication resource cost for each task,  $s_{n,i}^{\text{comm}}$  based on (9), (10) and (11)
21: User  $n$  computes the bids,  $p_{n,i}^b$  based on (13a)
22: GAISP  $m$  computes the asks,  $p_{m,j}^a$  based on (14a)
23: Auctioneer sorts the computed bids in the descending order in the set  $B$ 
24: Auctioneer sorts the computed asks in the ascending order in the set  $S$ 
25: for each bid  $p_{n,i}^b \in B$  do
26:   List the subset  $B'$  consisting of  $N_n$  bids of buyer  $n$ , we will perform the double auction algorithm on two sets  $B'$  and  $S$ 
27:   Remove  $N_n$  bids of buyer  $n$  from set  $B$ 
28:   Identify the breakeven index  $k$ , that is, the largest index such that  $p_{n,i}^b \geq p_{m,j}^a$ , with  $p_{n,i}^b$  and  $p_{m,j}^a$  are the  $k$ th elements of set  $B'$  and  $S$  respectively
29:   if  $k = N_n$  then
30:     Allocate the first  $k$  elements of set  $S$  in order with  $N_n$  elements of set  $B'$ 
31:     Payment price of each task of user  $n$ ,  $p_{n,i}^m$ , equals the next largest bid,  $p_{n,i+1}^b$ 
32:     Selling price for each task of GAISP  $m$ ,  $\gamma_{m,j}$ , equals the next smallest ask  $\gamma_{m,j+1}$ 
33:     Remove the winning tasks from the set  $S$ 
34:     Update the matching dictionary,  $M$ 
35:   else
36:     The buyer is not matched with any seller
37:   end if
38: end for
39: return  $M, p_{n,i}^m, \gamma_{m,j} = 0$ 

```

2) : Scenario 2: Each user doesn't require sufficient resources for all of its tasks to be successfully matched by the auctioneer.

$\mathcal{N}$	Scenario 1	Scenario 2	Greedy
50	0.5	0.2	5.1
60	0.6	0.9	4.2
70	0.7	0.3	4.9
80	1.0	0.3	4.8
90	0.9	0.4	7.1
100	0.9	0.4	7.5

TABLE II: Compare implementation time (mili-seconds)

Algorithm 2 Algorithm for Double Auction Mechanism - Scenario 2

```

INPUT:
2: Set of users:  $\mathcal{N} = \{1, \dots, n, \dots, N\}$ 
3: Set of GAISPs:  $\mathcal{M} = \{1, \dots, m, \dots, M\}$ 
4: Set of GAI tasks of user  $n$ :  $\mathcal{N}_n = \{1, \dots, i, \dots, N_n\}$ 
5: The similarity level between the input and the generated image of user  $n$ :  $\kappa_n, \forall n \in \mathcal{N}$ 
6: Height and weight of the image  $i$  of user  $n$ :  $H_{n,i}, W_{n,i}, \forall n \in \mathcal{N}, \forall i \in \mathcal{N}_n$ 
7: Data size of input image  $i$  of user  $n$ :  $s_{n,i}^{\text{in,img}}$ 
8: Data size of input prompt corresponding to image  $i$  of user  $n$ :  $s_{n,i}^{\text{in,prompt}}$ 
9: The maximum number of GAISP tasks that GAISP  $m$  can process simultaneously:  $M_m, \forall m \in \mathcal{M}$ 
10: Unit prices that the buyers are willing to pay for computation and communication resources:  $\xi_n^b, \eta_n^b$ 
11: Amounts and unit costs of resources of sellers:  $r_m^{\text{comp}}, r_m^{\text{comm}}, r_m^{\text{denoi}}, \xi_m^s, \eta_m^s, \zeta_m^s, \forall m \in \mathcal{M}$ 
12: OUTPUT:
13: Matching dictionary:

$$M = \left\{ ((i, n), (j, m)) := \text{task } i \text{ of user } n \right. \\ \left. \text{has been matched with task } j \text{ of GAISP } m \right\}$$

14: Payment price of task  $i$  of buyer  $n$ :  $p_{n,i}^m, \forall n \in \mathcal{N}, \forall i \in \mathcal{N}_n$ 
15: Payment price for task  $j$  of GAISP  $m$ :  $\gamma_{m,j}, \forall m \in \mathcal{M}, \forall j \in M_m$ 
16: ALGORITHM:
17: Initialize the matching dictionary,  $M = \{\}$ 
18: User  $n$  computes the number of denoising steps required by each task,  $\lambda_n$  based on (7)
19: User  $n$  computes the number of FLOPs required for the inference of each task,  $F_{n,i}$  based on (8)
20: User  $n$  computes the communication resource cost for each task,  $s_{n,i}^{\text{comm}}$  based on (9), (10) and (11)
21: User  $n$  computes the bids,  $p_{n,i}^b$  based on (13a)
22: GAISP  $m$  computes the asks,  $p_{m,j}^a$  based on (14a)
23: Auctioneer sorts the computed bids in the descending order in the set  $B$ 
24: Auctioneer sorts the computed asks in the ascending order in the set  $S$ 
25: Identify the breakeven index  $k$ , that is, the largest index such that  $p_{n,i}^b \geq p_{m,j}^a$ , with  $p_{n,i}^b$  and  $p_{m,j}^a$  are the  $k$ th elements of set  $B$  and  $S$  respectively
26: Allocate the first  $k$  elements of set  $S$  in order with  $N_n$  elements of set  $B$ 
27: Payment price of each successfully allocated task,  $p_{n,i}^m$ , equals to the bids of the next element in the set  $B$  of  $p_{n,i+1}^b$ 
28: Selling price for GAISPs for each successfully allocated task,  $\gamma_{m,j}$ , equals to the asks of the next element in the set  $S$  of  $p_{m,j+1}^a$ 
29: Remove the winning tasks from the set  $S$ 
30: Update the matching dictionary,  $M$ 
return  $M, p_{n,i}^m, \gamma_{m,j} = 0$ 

```

3.2. Deep Multi Agent Reinforcement learning

Tôi chia phần thực hiện training bằng Deep Multi Agent Reinforcement learning thành 2 kịch bản, mỗi kịch bản huấn luyện bằng cách sử dụng kết quả

Rewards ở Scenario hiện tại (1 hoặc 2) để huấn luyện các GAISP (hay các agent) chiến lược đặt giá tối ưu thông qua thuật toán Multi Agent Proximal Policy Optimization. Sau đó ghi nhận kết quả lợi nhuận cuối cùng bằng cách lấy ask của các GAISP được matching thành công ở round hiện tại trừ đi ask của các GAISP tương ứng ban đầu, coi như đây là giá gốc.

Công thức tính lợi nhuận của GAISP được tính như sau:

$$u_m = \gamma_{m,j} - p_{m,j}^s, \text{ nếu } \gamma_{m,j} \in Ws \quad (19)$$

$$0, \text{ nếu ngược lại}$$

Trong đó:


u_m là lợi nhuận của GAISP m

$\gamma_{m,j}$ là giá matching của task j của GAISP m

$p_{m,j}^s$ là giá vốn do GAISP m đặt cho task j

Ws là tập các task được matching thành công

Sơ đồ cho quá trình training được miêu tả như bên dưới:




Hình 3: Sơ đồ training của 2 kịch bản MAPPO.


4. Kết quả và kết luận

4.1. Scenario 1 và Scenario 2


Đối với Scenario 1 và Scenario 2, tôi đã sử dụng thuật toán Double Auction để tối ưu tổng lợi nhuận của Auctioneer. Theo đó, thuật toán tiến hành matching giữa các task của GAISPs và Users theo quy trình ở phần 3. Kết quả thu được được trình bày bằng đồ thị lợi nhuận của Auctioneer như bên dưới. Tôi cũng thêm vào cả đồ thị lợi nhuận của GAISPs và Users để thấy rằng mặc dù mục tiêu bài toán là tối ưu tổng lợi nhuận của Auctioneer nhưng tổng lợi nhuận của GAISPs và Users cũng là tốt, và do đó lợi nhuận toàn cục cũng được tối ưu.



Hình 4: Lợi nhuận của Auctioneer ở Scenario 1 và Scenario 2



Hình 5: Lợi nhuận của GAISPs ở Scenario 1 và Scenario 2



Hình 6: Lợi nhuận của Users ở Scenario 1 và Scenario 2


4.2. Scenario 3

Đối với Scenario 3, tôi đã huấn luyện hệ thống Multi Agents các GAISPs để đưa ra chiến lược đặt giá tối ưu nhằm tối ưu hóa tổng lợi nhuận của các GAISPs. Tôi đã huấn luyện hệ thống Multi Agents bằng 20 lần training, sử dụng thuật toán MAPPO như đã trình bày trong phần 3.


Kết quả được trình bày bằng đồ thị lợi nhuận của các GAISP qua từng vòng training dưới đây. Qua đồ thị ta có thể thấy rằng, lợi nhuận của các GAISP qua các vòng training có xu hướng tăng dần. Tuy nhiên ở từng vòng thì việc tăng của lợi nhuận các GAISP là chưa ổn định. Điều này có thể do nhiều nguyên nhân như:

- Giới hạn việc cập nhật ở trong thuật toán MAPPO còn cao. Để khắc phục điều này chúng ta có thể tinh chỉnh giới hạn phần cập nhật PPO trong thuật toán MAPPO.

- Learning Rate của Agent còn chưa hợp lý.
- Số lượng các episodes trong các hàm training có thể còn cao và chưa hợp lý.



Hình 7: Lợi nhuận ở Scenario 3 của Scenario 1 của GAISPs qua các lần training



Hình 8: Lợi nhuận ở Scenario 3 của Scenario 2 của GAISPs qua các lần training

Danh mục tài liệu tham khảo:

[1] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*. Springer International Publishing, 2015, pp. 234–241

[2] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli, “Deep unsupervised learning using nonequilibrium thermodynamics,” in *Proceedings of the 32nd International Conference on Machine Learning*, ser. *Proceedings of Machine Learning Research*, vol. 37, 2015, pp. 2256–2265.

- [3] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. u. Kaiser, and I. Polosukhin, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30. Curran Associates, Inc., 2017.
- [4] A. Jaegle, F. Gimeno, A. Brock, O. Vinyals, A. Zisserman, and J. Carreira, “Perceiver: General perception with iterative attention,” in *Proceedings of the 38th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 139. PMLR, 2021, pp. 4651–4664.
- [5] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, G. Sastry, A. Askell, P. Mishkin, J. Clark, G. Krueger, and I. Sutskever, “Learning transferable visual models from natural language supervision,” 2021.
- [6] C. Meng, Y. He, Y. Song, J. Song, J. Wu, J.-Y. Zhu, and S. Ermon, “Sdedit: Guided image synthesis and editing with stochastic differential equations,” 2022. [Online]. Available: <https://arxiv.org/abs/2108.01073>
- [7] L. Yang, Z. Zhang, Y. Song, S. Hong, R. Xu, Y. Zhao, W. Zhang, B. Cui, and M.-H. Yang, “Diffusion models: A comprehensive survey of methods and applications,” *ACM Computing Surveys*, vol. 56, no. 4, pp. 1–39, 2023
- [8] Richard S. Sutton and Andrew G. Barto, *Reinforcement Learning: An Introduction*, Second edition, The MIT Press, 2018